

# 線形モデルによるレビュー個性を生かした映画推薦とその要因の評価

神戸大学 ○渡邊 咲樹, 村尾 元

## Personalized Movie Recommendation using Linear Models: Reviewer-Aware Contribution Analysis

Watanabe Saki, Murao Hajime, Kobe University

**Abstract** This study proposes an explainable movie recommendation model using a group-wise linear regression framework. User ratings are decomposed into four additive components, enabling stable and interpretable contribution analysis. Experiments on an IMDb-based dataset confirm that the method achieves practical accuracy while revealing consistent user evaluation tendencies.

**Keywords:** Recommender System, Movie, Explainability, Linear Model

### 1 はじめに

映画推薦システムにおいて、精度の高い評価予測は重要であるが、同時に「なぜその評価になるか」の理解も推薦の質を左右する。特に映画のような嗜好性の高いコンテンツでは、レビューごとに重視する観点が大きく異なる。ある人は俳優を、別の人には監督を、さらに別の人にはジャンルやストーリー内容を主な判断基準とする。こうした個性を無視した推薦では、たとえ予測精度が高くても利用者の納得感を得にくい。

個性を生かした推薦を実現するには、まず「レビュー者が何を重視して評価しているか」という要因を定量的に把握する必要がある。本研究では、評価を複数の要因系列に分解し、各要因の寄与を数値化する線形モデルを提案する。さらに、抽出された要因構造を分析することで、レビュー個性のパターンを明らかにし、個性ベース推薦の基盤となる評価要因の定量化手法を示す。

### 2 関連研究

推薦システムの透明性を高める説明可能性(Explainability)は近年重要な課題であり、特徴ベース手法からLLMを用いた生成型手法まで多様なアプローチが体系化されている[1]。特に、評価根拠を明示するため、ユーザーやアイテムの潜在表現を解釈可能なアスペクトに写像する手法や、アテンションにより重要度を可視化する研究が進んでいる[2,3]。映画推薦でも、レビューやメタデータから嗜好要因を抽出する試みが行われているが[4]、これらをuser/movie等の構造系列に分解し、線形モデルの安定性を用いて要因寄与を一貫して定量化する枠組みは依然として独自性が高い。

### 3 提案手法

**3.1 モデルの基本構造** 提案手法 GLR (Group-wise Linear Regression with Regularization) は、評価予測を次の線形モデルで表す：

$$\hat{y} = b + \sum_{g=1}^{17} w_g^\top x_g$$

ここで、予測評価値を  $\hat{y}$ 、バイアス項を  $b$ 、特徴グループ(全 17 グループ)を  $g$ 、重みベクトルを  $w_g$ 、特徴ベクトルを  $x_g$  とする。本研究の核心は、17 グループを意味的に 4 系列に集約することで、評価要因を明確化する点にある：

$$\hat{y} = b + \text{User} + \text{Movie} + \text{Interaction} + \text{Review}$$

各系列の役割は以下の通りである：

- User 系列 (686 次元)：レビュー者の俳優・監督嗜好の埋め込み、ジャンル別評価傾向、レビュー統計から抽出した感情特性を含む。
- Movie 系列 (1202 次元)：映画の俳優・監督・キーワード埋め込み、タグ、ジャンル情報を格納する。
- Interaction 系列 (80 次元)：User 嗜好と Movie 属性の類似度や要素積により相性を表現する。
- Review 系列 (22 次元)：個別レビューのトピック別感情スコアを捉える。

この 4 系列分解により、線形構造の性質上、各系列の寄与は  $w_g^\top x_g$  の和として数学的に一意に決定される。そのため、「どの要因がどの程度影響したか」を安定的に解釈できる。

**3.2 レビュアー個性を引き出す正則化** Movie 系列は次元数（1202 次元）が大きく、放置すると寄与が過度に優勢になる。これを抑え、User 系列に個性を適切に反映させるため、3 種の正則化を導入した。

(1) Movie Suppression Movie 系列の寄与を抑え、User/Movie のバランスを保つ。これにより、実際に見られる「人による評価差」を線形モデルで再現できる。

(2) Inter-group Correlation User と Movie の重み相関を下げ、両系列が独立した情報を保持するよう制御する。

(3) Intra-group Variance 高次元で特定次元に重みが集中することを防ぎ、多面的な嗜好表現を確保する。

これらの正則化により、User 系列は「個人の判断基準」、Movie 系列は「作品の特徴」を明確に分離でき、この構造が本研究における個性抽出の基盤となる。

**3.3 データセット** IMDb データセットから得た 735 ユーザー・1247 作品・36003 レビューを用い、70/12/18 個人差を補正した。特徴量には、TMDb から取得したメタデータ、GPT-4 によるトピック・感情分類、FastText (300 次元) による埋め込みを用いた。

#### 4 性能と評価要因の抽出

**4.1 予測性能** GLR は Test MAE が 0.656 となり、Simple Linear (0.865) 比で 24% 改善した。同一レビュアー内の User 寄与分散 (0.581) は、同一映画に対する Movie 寄与分散 (0.285) の約 2 倍であり、評価が作品の一般的な特徴よりもレビュアー固有の判断基準に強く依存することを示している。

**4.2 評価要因の定量化とクラスタ分析** User 系列から抽出した 6 軸要因 (actor, director, genre, content, interaction, background) を用いて、レビュアーごとの評価傾向を定量化した。6 軸の平均ベクトルに対して K-means ( $k = 6$ ) を適用した結果、以下の 6 種の評価パターンが得られた：

**Actor-Focused** (87 名), **Director-Focused** (130 名), **Genre-Focused** (135 名), **Content-Focused** (113 名), **Multi-Signal** (76 名), **Balanced** (194 名)。

図 1 はそれぞれの 6 軸寄与を可視化したものであり、Actor-Focused と Director-Focused の突出した違い、Genre-Focused と Content-Focused の構造的対照性、Balanced の均衡傾向が確認できる。

#### 5 まとめ

本研究では、映画評価を User · Movie · Interaction · Review の 4 系列に線形分解する枠組みを導入し、レビュアーがどの情報を基準に作品を判断しているかを安定的に抽出できることを示した。User 系列の分散が Movie 系列の 2 倍以上であったことから、評価が作品そのものより

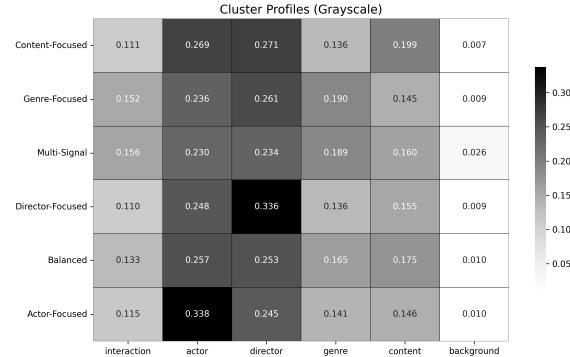


図 1: 6 種類の評価パターンにおける 6 軸寄与のヒートマップ

も個人の判断基準に強く依存することが確認され、個性を考慮した推薦の重要性が裏付けられた。

さらに、User 系列から得られる 6 軸要因に基づきクラスタ分析を行い、俳優重視・監督重視・ジャンル重視・内容重視など 6 種の評価パターンを同定した。効果量の分析により、これらの違いが統計的に実質的な構造を持つことも確認した。

本手法により、ユーザーが「何を理由に映画を評価しているか」を系列単位で把握できるため、従来の属性ベース推薦に加え、各ユーザーの判断軸に即した説明生成が可能となる。今後は、要因構造を推薦アルゴリズムへ直接反映し、ユーザーの評価スタイルに応じて推薦重みを動的に切り替える仕組みの構築を進めるとともに、自身の評価軸を理解しながら作品を探索できるインタラクティブな UI の実現を目指す。

#### 参考文献

- Y. Zhang and X. Chen: Explainable Recommendation: A Survey and New Perspectives, *Foundations and Trends in Information Retrieval*, 14(1), 1–101 (2020).
- D. Pan, et al.: Explainable Recommendation via Interpretable Feature Mapping, *Proceedings of IJCAI 2020*, 2690–2696 (2020).
- N. Tintarev, et al.: A Survey of Explainable Recommender Systems, *Computer Science & Information Technology*, 14, 159–175 (2024).
- 村上: テキストマイニングとネットワーク分析を用いた映画評価の分析, *経営論集*, 29(2), 26–40 (2014).